

Teste avaliativo para vaga de bolsista em engenharia/análise de dados

- Dimensões : 10 x 31

-Tipos de variáveis:

Titulo	Colunas
Texto (object/string)	Nome,endereço,descrição,uf,natureza,,idUnico,especie,natureza,naturezaOutras,situacao,descPlanoNacionalPoliticaVinculado,descPopulacaoBeneficiada,observacoesPertinentes,tomadores,executores,repassadores,eixos,tipos,subTipos,fontesDeRecurso,metaGlobal
Numéricas (int/float)	qtdEmpregosGerados,populacaoBeneficiada
Datas (datetime)	DataCadastro,DataInicialPrevista,dataFinalPrevista,dataSituacao,dataInicialEfetiva,dataFinalEfetiva,
Booleano	isModeladaPorBim

-Taxas de valores nulos:

Grupo 0.0% (Colunas Completas)

- idUnico
- nome
- descricao
- funcaoSocial
- metaGlobal
- dataInicialPrevista
- dataFinalPrevista
- dataCadastro
- especie
- natureza
- situacao

- uf
- dataSituacao
- tomadores
- executores
- repassadores
- eixos
- tipos
- subTipos
- fontesDeRecurso

Grupo 30.0%

- isModeladaPorBim

Grupo 40.0%

- cep
- endereco

Grupo 60.0%

- naturezaOutras

Grupo 80.0%

- descPlanoNacionalPoliticaVinculado
- descPopulacaoBeneficiada

Grupo 90.0%

- qdtEmpregosGerados
- populacaoBeneficiada

Grupo 100.0% (Colunas Vazias / Baixa Qualidade)

- dataInicialEfetiva
- dataFinalEfetiva
- observacoesPertinentes

Estatísticas descritivas :

Estatística	Valor	Descrição
Contagem	31	Número total de colunas avaliadas.
Média	26.13%	A porcentagem média de dados ausentes nas colunas.
Desvio Padrão	38.96%	Indica uma alta variabilidade, mostrando que as porcentagens estão muito dispersas em relação à média (muitos valores em 0% e muitos valores altos).

Conclusão sobre a Qualidade dos Dados

A qualidade geral do conjunto de dados apresenta uma **dicotomia forte** (separação entre extremos), onde a maioria das colunas é de excelente qualidade, mas uma minoria significativa tem sérios problemas de completude.

Pontos Fortes (Alta Qualidade):

1. Alta Completude na Maioria dos Campos:

- **Moda e Mediana:** Ambos são 0.0%. **20 das 31 colunas** (aproximadamente 64.5%) estão completamente preenchidas (0.0% de ausência).
- **Foco Principal:** Os dados de identificação (`idUnico`, `nome`), de controle (`dataCadastro`, `situacao`, `uf`, etc.), e de organização da obra (`tipos`, `eixos`, etc.) estão robustos.

2. Baixo Risco para Análises Base:

- A grande quantidade de colunas com 0.0% de incompletude sugere que as análises e agregações baseadas nesses campos podem ser feitas com alta confiança.
-

Pontos Fracos (Baixa Qualidade e Risco):

1. Incompletude Extrema em Campos Críticos:

- **Três colunas** (`dataInicialEfetiva`, `dataFinalEfetiva`, `observacoesPertinentes`) estão **totalmente vazias (100.0%)**, tornando-as inúteis para análise.
- **Campos Operacionais Críticos:** As datas efetivas estão 100% ausentes, indicando que não há registro de quando as obras realmente começaram/terminaram.

2. Altos Níveis de Incompletude em Campos de Impacto/Detalhe:

- Campos relacionados ao **impacto social** e **planejamento** (qdtEmpregosGerados, populacaoBeneficiada, descPlanoNacionalPoliticaVinculado, descPopulacaoBeneficiada) têm entre 80.0% e 90.0% de dados ausentes. Isso compromete a avaliação do propósito e do resultado do projeto.
- Detalhes de **localização** (cep e endereco) têm 40.0% de incompletude, dificultando análises geográficas.

3. Alta Variabilidade:

- O **Desvio Padrão** de $\approx 38.96\%$ é alto, confirmando que a qualidade não é homogênea: é excelente em um grupo de colunas e muito ruim em outro.

-Normalização dos dados:

Nome Original	Nome Normalizado (snake_case)
idUnico	id_unico
nome	nome
descricao	descricao
funcaoSocial	funcao_social
metaGlobal	meta_global
dataInicialPrevista	data_inicial_prevista
dataFinalPrevista	data_final_prevista
dataCadastro	data_cadastro
especie	especie
natureza	natureza
situacao	situacao
uf	uf
dataSituacao	data_situacao
tomadores	tomadores
executores	executores
repassadores	repassadores

Nome Original	Nome Normalizado (snake_case)
eixos	eixos
tipos	tipos
subTipos	sub_tipos
fontesDeRecurso	fontes_de_recurso
isModeladaPorBim	is_modelada_por_bim
cep	cep
endereco	endereco
naturezaOutras	natureza_outras
descPlanoNacionalPoliticaVinculado	desc_plano_nacional_politica_vinculado
descPopulacaoBeneficiada	desc_populacao_beneficiada
qdtEmpregosGerados	qtd_empregos_gerados
populacaoBeneficiada	populacao_beneficiada
dataInicialEfetiva	data_inicial_efetiva
dataFinalEfetiva	data_final_efetiva
observacoesPertinentes	observacoes_pertinentes

-Relatório de Inconsistências e Anomalias de Dados

As inconsistências e anomalias de dados identificadas baseiam-se nas taxas de incompletude fornecidas, indicando problemas de qualidade que precisam de atenção para garantir a confiabilidade das análises.

1. Inconsistência Crítica: Ausência de Rastreamento Efetivo

As colunas **data_inicial_efetiva** e **data_final_efetiva** apresentam uma ausência total de dados (**100.0% de incompletude**). Esta é a anomalia mais grave, pois impede qualquer avaliação temporal dos projetos. É impossível determinar a duração real, rastrear o progresso ou verificar a aderência aos prazos originais.

2. Anomalia em Campo de Observação

O campo **observacoes_pertinentes** está **totalmente vazio (100.0% de incompletude)**. Esta anomalia elimina qualquer contexto qualitativo, notas importantes ou informações não estruturadas que seriam cruciais para entender as especificidades, desafios ou sucessos de cada projeto.


3. Análise e Melhoria de Colunas Redundantes: data_cadastro e data_situacao

A sugestão de que **data_cadastro** e **data_situacao** cumprem o mesmo papel com os mesmos dados, e que uma pode ser substituída, aponta para uma falha na modelagem do banco de dados.

-Armazenamento dos Dados:


```
criabanco.py > ...
1  import pandas as pd
2  import sqlite3
3
4
5  ARQUIVO_EXCEL = 'tabela_tratada.xlsx'
6  NOME_TABELA = 'dados_tratados'
7  NOME_DB = 'dados_tratados.db'
8  df = pd.read_excel(ARQUIVO_EXCEL)
9  conexao = sqlite3.connect(NOME_DB)
10 df.to_sql(NOME_TABELA, conexao, if_exists='replace', index=False)
11 conexao.commit()
12 conexao.close()
13
14
15
16 |
```

-Script em Python para carregar dados de uma planilha Excel (.xlsx) e transferi-los para um banco SQLite.



-Banco no DB Browser

Análise Qualitativa



Padrões e inconsistências observados

- Padrão 1 — Alta completude em dados administrativos**
 Colunas como `id_unico`, `nome`, `situacao`, `uf`, `tipos` e `eixos` estão 100% preenchidas.
- Padrão 2 — Ausência quase total de dados operacionais**
 Campos de execução real (`data_inicial_efetiva`, `data_final_efetiva`) estão vazios.
- Padrão 3 — Falhas em informações de impacto social**
 Variáveis como `qtd_empregos_gerados` e `populacao_beneficiada` têm entre 80% e 90% de ausência.
- Padrão 4 — Redundância e inconsistência em campos de data**
`data_cadastro` e `data_situacao` parecem representar momentos similares, indicando possível duplicação.

Hipóteses e possíveis causas

1. Falta de integração entre sistemas:

As informações operacionais podem estar em outro banco ou sistema que não foi sincronizado com esta base.

2. Etapa de coleta incompleta ou descentralizada:

Cada órgão responsável pode ter padrões diferentes de preenchimento — o que explicaria as discrepâncias entre colunas completas e vazias.

3. Campos opcionais em formulários:

É possível que campos como “empregos gerados” e “população beneficiada” não sejam obrigatórios no sistema de entrada de dados.

4. Obras ainda em andamento:

A ausência das datas efetivas pode indicar que grande parte das obras ainda não foi iniciada ou concluída.

Conclusão e comunicação simplificada

Em termos simples:

O conjunto de dados é **confiável para identificar e caracterizar obras**, mas **não confiável para avaliar seus resultados ou prazos**.

- As colunas principais (identificação e categorização) estão completas e bem estruturadas.
- Contudo, os dados que medem **impacto e execução real** estão **muito incompletos**.
- Isso significa que podemos **saber o que está planejado**, mas **não avaliar o que foi feito**.